

基于RK3588的低时延多模态虚拟陪伴机器人

设计报告（瑞芯微赛题·自主选题）

团队名称：VeyraLux微睿霖光 团队编号：12255 团队成员：王文康、夏鑫祥

摘要

本作品基于 ELF 2 开发板（主控芯片 RK3588）构建低时延多模态虚拟陪伴机器人。系统将开发板定位为端侧智能中枢：在板端完成视觉检测、人脸与情绪分析、语音识别、语音合成、长期记忆与服务编排，同时通过 Cloudflare 安全入口向 PC 与移动浏览器提供统一交互界面。Web 前端只承担摄像头、麦克风采集和 Live2D 呈现，不替代核心推理；云端仅用于大语言模型对话规划与公网可达性。作品面向日常聊天、情感陪伴和人机交互展示，重点解决“能看见、能听懂、能回应、能表现”的闭环体验。经实测，板端 SenseVoice 在真实语音样本上局域网识别约 0.35 s，宽带噪声样本不触发识别；RK3588 视觉链路可返回人物、动作与背景语义，并将 Qwen3-VL 量化模型输出注入对话上下文；默认 Matcha 语音热路径板端约 0.44 s，VoxCPM 参考音色作为高质量短句后端按需启动并释放。系统以工程稳定性和可展示性为目标，兼顾端侧推理、移动访问和后续扩展。

关键词：RK3588；多模态交互；端侧推理；Live2D；语音识别；视觉语言模型

第一部分 作品概述

1.1 功能与特性

系统围绕虚拟陪伴场景建立“视觉—听觉—对话—表达”闭环。用户通过 robot.veyralux.org 访问交互页面，浏览器采集图像与音频后发送至 ELF2。开发板在本地运行 YOLO、YuNet/SFace、FER+、Light-ASD、SenseVoice、Matcha-TTS 与 VoxCPM.cpp 等模块，形成对人物、表情、语音和环境的综合判断；对话层读取当前视觉上下文、最近对话和长期记忆，生成 Live2D 表情、动作、文本和语音。系统支持 PC 与移动端浏览器，默认公网入口不要求用户处于开发板同一局域网。

1.2 应用领域

作品可用于个人桌面陪伴、智能硬件展示、人机交互课程实验和多模态模型部署验证。与传统嵌入式控制类作品不同，本系统将 ELF2 作为具备本地推理能力的“边缘智能节点”，把复杂交互层放在跨平台 Web 中，使作品更容易在展台、手机和电脑上展示，同时保留开发板在感知与语音链路中的核心作用。

1.3 主要技术特点

- 端侧多进程协同：视觉、语义视觉、统一控制、Cloudflare Tunnel 以 systemd 服务常驻，VoxCPM 按请求启动，避免长期占用内存。

- 真实视觉语义：YOLO/Pose/人脸输出低延迟结构化信息，Qwen3-VL 量化模型补充人物动作、背景和场景描述。
- 低等待感语音交互：WebSocket 边录边传，句尾只触发识别完成；VAD 使用独立句段引擎，降低噪声误触发。
- 拟人化表现：Live2D 模型支持动作、表情、口型同步、自然待机和触摸/指针跟随。
- 公网可达：Cloudflare Worker + VPC Service + Tunnel 连接 ELF2，用户可直接访问 robot.veyralux.org。

1.4 主要性能指标

指标	实测结果	说明
ASR 局域网真实语音	约 355 ms	6.35 s 参考语音，文本正确
ASR 噪声样本	不触发识别	speech_ratio 约 0.0606
视觉局域网关键帧	约 259-634 ms	含目标、人脸、姿态、缓存语义
Matcha TTS 板端	约 0.44 s	默认连续对话音色
Matcha TTS 公网热路径	约 1.8 s	经正式域名访问
VoxCPM 参考音色	约 14.0 s	短句高质量音色，完成后释放进程
强验收内存余量	约 3.0 GiB available	四项常驻服务 + Vox 空闲释放后

表1 关键链路实测性能摘要

1.5 主要创新点

- 将比赛开发板作为多模态端侧推理与服务编排中心，兼顾嵌入式平台能力和 Web 展示效率。
- 在轻量检测结果之外引入量化视觉语言模型，使角色能引用人物动作和背景环境。
- 将高质量 VoxCPM 音色设计为按需后端，既保留音色效果，又避免与视觉模型长期争抢 8 GiB 共享内存。
- 建立一键启动和强校验脚本，把服务状态、本地接口、公网回源、模型校验和进程释放纳入验收。

1.6 设计流程

设计流程为：需求拆解与场景定义；建立 ELF2 本地推理环境；完成视觉、语音、对话和 Live2D 的最小闭环；引入公网访问和移动端适配；根据实测优化 ASR 噪声门控、视觉语义刷新、TTS 启动策略和服务恢复；最后形成部署脚本、强验收脚本和提交材料。

第二部分 系统组成及功能说明

2.1 整体介绍

系统由交互层、边缘入口、ELF2推理中枢和模型资源层组成。交互层负责采集与呈现；边缘入口提供访问和设备令牌代签；ELF2统一网关协调视觉、语音、记忆与对话；模型资源层包含RKNN、ONNX、GGUF/GGML 等本地模型。模块关系如图1所示。




图1 系统总体框图

2.2 硬件系统介绍

硬件平台为 ELF 2 开发板，主控芯片 RK3588，板端承担本地视觉推理、音频处理、模型服务和公网隧道连接。外设包括摄像头、麦克风、扬声器或浏览器播放设备。由于当前作品以“裸板+网络交互”为主要形态，未设计额外机械结构和自制电路板；硬件成果重点体现为对 RK3588 CPU/NPU/内存资源的调度，以及在稳定供电和网络环境下的本地服务部署。

2.3 软件系统介绍

软件采用 Python 后端、Vite/JavaScript 前端、systemd 服务编排和 Cloudflare 边缘入口。视觉服务对图像进行目标检测、姿态估计、人脸检测、身份特征匹配和情绪分析；语义视觉服务使用 Qwen3-VL 量化模型输出自然语言场景描述；语音服务包括 SenseVoice ASR、Matcha-TTS 默认音色和 VoxCPM.cpp 参考音色；对话服务综合视觉上下文、长期记忆和 DeepSeek Flash 生成结构化控制计划。

模块	关键输入	关键输出	运行位置
视觉网关	JPEG 图像	人数、物体、人脸、情绪、姿态、语义描述	ELF2
实时 ASR	16 kHz PCM	识别文本、语音比例、有效时长	ELF2
TTS	文本、语速、音色	WAV 音频	ELF2

Live2D 舞台	控制计划、音频	动画、口型、状态提示	浏览器
公网入口	HTTPS/WSS 请求	转发、缓存、鉴权	Cloudflare + ELF2

表2 软件模块输入输出关系

第三部分 完成情况及性能参数

3.1 整体介绍

目前系统已在

上完成四项常驻服务部署：emotion、VLM、control、cloudflared；VoxCPM 不作为常驻服务，而由控制网关在语音请求期间启动并在结束后释放。正式访问入口为 robot.veyralux.org，移动端页面已能展示 Live2D 角色、聊天气泡和输入区。

ELF2




图2 移动端公网访问界面截图

3.2 工程成果

软件成果包括统一控制服务、视觉语义服务、实时 ASR 通道、VoxCPM.cpp 板端适配器、响应式 Web 舞台、一键部署脚本和强验收脚本。系统已通过本地回归测试：Python 130 项、Web 8 项、小游戏保留回归 35 项。板端强验收显示四个 systemd 服务均运行，VoxCPM 模型 SHA-256 正确，公网入口可回源，空闲状态无 voxcpm-server 残留。

3.3 特性成果与量化指标

ASR 方面，修复了 WebRTC VAD 历史状态污染问题：完整句段识别使用无历史状态的新 VAD 实例，避免上一句真人语音导致下一段噪声被误判。实测噪声样本 `speech_ratio` 约 0.0606，低于 0.08 门限，不进入 SenseVoice 解码；真实参考语音能正确识别为“很高兴认识你哦，我刚刚买了杯珍珠奶茶，我们一起去公园长椅上坐坐吧”。

视觉方面，系统不再只告诉角色“画面中有几个人”。在示例图像中，Qwen3-VL 量化模型输出“两位男性教练、一人指向前方、另一人张嘴说话、背景是体育场看台”等语义，随后对话回复能直接引用这些画面细节，证明视觉上下文已进入对话规划。

语音合成方面，默认 Matcha 音色用于实时连续对话；VoxCPM 使用 `soft_girl` 参考音色，在 RK3588 CPU 上可完成高质量短句合成，短句约 14s，结束后进程释放。该策略以交互稳定为优先，同时保留高质量音色演示能力。

第四部分 总结

4.1 可扩展之处

后续可从三方面扩展：一是增加多帧姿态跟踪，使坐下、起身、挥手等状态更稳定；二是继续优化公网 WebSocket 首次建连延迟，降低移动网络下的等待感；三是探索更适合 RK3588 的流式高质量 TTS 或 NPU/ONNX 音色迁移，使 Vox 级音色逐步接近实时。

4.2 心得体会

本项目的主要挑战不在单个模型能否运行，而在有限内存、实时交互和公网可达之间取得平衡。RK3588 提供了端侧推理基础，但视觉、语音、对话和动画同时运行时，需要明确区分常驻服务与按需服务。通过多轮实测，我们将 ELF2 定位为“边缘智能中枢”，用 Web 承担交互呈现，用 `systemd` 和强验收脚本保障运行稳定。该实践说明，嵌入式平台也可以承载较完整的多模态体验，但必须用工程化方式管理模型、进程、内存、网络 and 用户等待感。

第五部分 参考文献

- [1] Rockchip. RK3588 Processor Datasheet and Developer Documentation[EB/OL].
- [2] k2-fsa. sherpa-onnx: Offline speech recognition and text-to-speech toolkit[EB/OL].
- [3] Cloudflare. Workers, Tunnel and VPC Services Documentation[EB/OL].
- [4] Live2D Inc. Cubism SDK Manual[EB/OL].
- [5] OpenBMB / VoxCPM.cpp Project Documentation[EB/OL].